# HW2: 多元線性迴歸 - GPT 輔助內容與對話紀錄

專案儲存庫：mumumush/HW2-Multiple-Linear-regression ｜ 日期：2026-10-22

## 一、AI 輔助歷程與提問策略 (Prompt Engineering Summary)

在本次作業進行過程中，AI 助手（ChatGPT / Antigravity）提供以下四大面向之核心技術諮詢與架構支援：

1. CRISP-DM 流程標準化：遵循商業理解、資料理解、資料前處理、建模、評估到部署之完整工程規範。

2. 資料集規格篩選：嚴格過濾符合老師「特徵數 14~39 且非分類任務」之要求，選用 Kaggle King County 房價資料集（18 特徵、21,613 筆樣本）。

3. 統計推論區間計算：推導多元線性迴歸之槓桿值 h_00，同時精確計算 95% 信賴區間 (CI) 與 95% 預測區間 (PI)。

4. Web 部署與防呆機制：建置 Streamlit 應用程式之 Problem 下拉切換 (+1 分) 與自訂 CSV URL 載入防護罩 (+2 分)。

## 二、關鍵對話紀錄節錄 (Key Dialogue Transcript)

【對話節錄 1：資料集篩選與任務規格】
學生問：我要找適合 Multiple Linear Regression 的 Kaggle 公開資料集，條件是特徵數必須在 14 到 39 之間，且不可以做 classification，請問有哪些適合？

AI 回覆重點：推薦首選 House Sales in King County, USA。
• 樣本數 21,613 筆，特徵數 18 個（嚴格符合 14~39 限制）。
• Target 為連續價格 price，完全符合連續迴歸要求。
• 包含室內面積、等級、建成年份等多重特徵，極度適合進行 Lasso 特徵選擇與 Baseline 對比實驗。

【對話節錄 2：信賴區間 (CI) 與預測區間 (PI) 數學推導】
學生問：老師要求預測圖必須加上信賴區間或預測區間，而且強調不能隨便自行畫上下界，必須用統計上合理的方法計算，公式該如何實作？

AI 回覆重點：在多元線性迴歸中，必須依據樣本共變異數矩陣 (X^T X)^(-1) 計算測試點的槓桿值：
• 槓桿值：h_00 = x_0 * (X^T X)^(-1) * x_0^T
• 95% 信賴區間 (Mean Response CI)：y_hat ± t(alpha/2, df) * s * sqrt(h_00)
• 95% 預測區間 (Individual Observation PI)：y_hat ± t(alpha/2, df) * s * sqrt(1 + h_00)
預測區間額外計入了單一觀測值的隨機誤差項變異，因此範圍必然寬於信賴區間。

【對話節錄 3：加分功能實作與防呆機制】
學生問：老師加分要求：1. 下拉視窗呈現兩種 Problem (+1分)；2. 可任意輸入 Dataset CSV URL (+2分)。如果使用者輸入錯誤網址該怎麼辦？

AI 回覆重點：在 src/data_loader.py 與 app/app.py 中建立多層防護罩：
1. 檢查 URL 是否可連線（攔截 HTTP 404/500/SSL 錯誤）。
2. 檢查 CSV 格式是否有效、樣本數是否足夠（>= 30 筆）、是否有數值型 Target。
3. 若不符合要求以友善錯誤訊息提示，絕不讓 Streamlit 伺服器異常崩潰 (Crash)。